МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «КУРСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»

Факультет физики, математики, информатики Кафедра программного обеспечения и администрирования информационных систем

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА (бакалаврская работа)

на тему: ИНТЕЛЛЕКТУАЛЬНАЯ СИСТЕМА КЛАСТЕРИЗАЦИИ ДЛЯ ПРОДУКТОВОГО МАГАЗИНА

Обучающегося 4 курса очной формы обучения направления подготовки 02.03.03 Математическое обеспечение И администрирование информационных систем Направленность (профиль) Проектирование информационных систем и баз данных Мвеемба Элиас Мунсанда Руководитель: д.п.н., профессор Кудинов В.А. Допустить к защите: и.о. заведующего кафедрой

(подпись)

/Макаров К.С./

СОДЕРЖАНИЕ

Введение	4
1 Анализ требований к информационной системе	6
1.1 Описание и анализ предметной области	6
1.1.1 Алгоритма K-means кластеризации	
1.1.2 Алгоритм анализа RFM	10
1.2 Обзор и анализ возможных альтернатив	12
1.3 Анализ функциональных и эксплуатационных требований	12
1.3.1 Стандарты	12
1.3.2 Функциональные требования пользователя	13
1.3.3 Входные данные	13
1.3.4 Выходные данные	14
1.3.5 Требования к интерфейсу	14
1.3.6 Требования к надежности	14
1.3.7 Требования к программной документации	14
1.3.8 Требования к составу и параметрам технических средств	15
1.3.9 Модель вариантов использования	15
1.3.9.1 Диаграмма вариантов использования	15
1.3.9.2 Описание варианта использования «Выполнить кластеризацию»	16
2 Проектирование информационной системы	
2.1 Разработка архитектуры системы	
2.2 Разработка модели предметной области	
2.3 Разработка алгоритма функционирования системы	
2.4 Проектирование интерфейса пользователя	26
2.5 Реляционная модель данных	26
2.6. Проектирование классов предметной области	27
2.6.1. Построение диаграмм последовательностей для варианта	
использования «Выполнить кластеризацию»	27
2.6.2 Построение диаграммы кооперации	27
3 Реализация системы	. 29

3.1 Реализация программного обеспечения системы	29
3.1.1 Разработка диаграммы компонентов	29
3.1.2 Объекты интерфейса пользователя	29
4 тестирование и оценка трудоемкости разработки программного	
продукта	32
4.1 Тестирование программного продукта	
4.1.1 Функциональное тестирование	32
4.1.2 Тестирование пользовательского интерфейса	
4.1.3 Модульное тестирование	34
4.2 Оценка трудоемкости создания программного продукта	36
Заключение	40
Приложение А Текст программы	42
Приложение Б Программный код модульных тестов	48
Приложение В Внешний вид графического материала	51

Введение

Разрабатываемый программный продукт является системой кластеризации пользователей магазина в целях определения их предпочтений и формирования рекомендаций по рекламе.

Кластеризация — это задача разделения совокупности данных на несколько групп таким образом, чтобы совокупности данных в группах были более похожи на другие совокупности данных в той же группе и отличались от совокупности данных в других группах. Кластеризация очень важна, поскольку она определяет внутреннюю группировку среди имеющихся немаркированных данных. Из-за вышеупомянутой важности можно использовать в интернетмагазине продуктов для группировки клиентов в разные группы в зависимости от различных факторов:

- какие товары они покупают,
- как часто они покупают эти товары,
- когда они покупают эти продукты,
- какие продукты они чаще всего просматривают на сайте или в приложении и т. д.

Использование различных выделенных групп, основанных на общих свойствах этих групп, дает возможность отображать продукты, которые являются наиболее важными для каждого покупателя, и дает возможность предсказать, что покупатель может купить в какое-то конкретное время года.

Целью разработки приложения является создание системы кластеризации, которая группирует клиентов интернет-магазина продуктов в несколько групп и дает предложения о том, какие продукты рекламировать для каждой результирующей группы.

Основными задачами разработки являются:

- 1. Формирование групп на основе кластеризации.
- 2. Обеспечение доступа к истории покупок клиентов.

3. Обеспечение просмотра различных выделенных на основе кластеризации групп с целью формирования предложений для рекламы.

Программный продукт предназначен для использования в любом онлайн магазине.

Для разработки программного продукта применяется среда Sublime text. Вместе с СУБД Microsoft SQL server management studios для создания информационной системы используется CASE-средство Rational Rose Enterprise Edition v2001a.

Аннотация: в выпускной квалификационной работе рассмотрены основные моменты проектирования и разработки системы кластеризации пользователей магазина. группирует клиентов интернет-магазина продуктов в несколько групп и дает предложения о том, какие продукты рекламировать для каждой результирующей группы.

Abstract: in the final qualifying work, the main points of design and development of a clustering system for store users are considered. groups customers of an online product store into several groups and gives suggestions on which products to advertise for each resultant group.

1 Анализ требований к информационной системе

1.1 Описание и анализ предметной области

В настоящее время предлагаемые продукты на сайтах продуктов выбираются случайным образом, этот способ выбора предложений делает пользовательский опыт менее удобным и снижает шансы клиента или пользователя сайта купить столько продуктов, сколько они купили бы, если бы им были предоставлена реклама необходимых продуктов.

Вышеупомянутые недостатки создают необходимость в системе, которая помогала бы обрабатывать пользовательские данные и предоставляла наилучшие предложения на основе истории обращений пользователей.

Система позволит обеспечить:

- предоставление лучших индивидуальных предложений по продукту для каждого отдельного пользователя;
- использование лучшего пользовательского опыта, потому что клиенты будут иметь дело только с продуктами, которые их интересуют;
- предоставление важных данных о пользователях менеджеру продуктового магазина, что поможет ему определить, какими и когда продуктами следует запастись.

Система будет использоваться менеджером любого интернет-магазина товаров. При наличии данных о пользователях, таких как предыдущие покупки, система будет фильтровать данные и группировать их в группы со сходством и предоставлять индивидуальные предложения для каждого клиента.

На рисунке 1 и рисунке Б.10 представлена контекстная DFD-диаграммы системы интеллектуальная система кластеризации для продуктового магазина в BPWin. Входными данными служит информация о покупателях (Market segmentation system) с выходными графиками (Graph) и таблицами (Table) с результатами анализа.

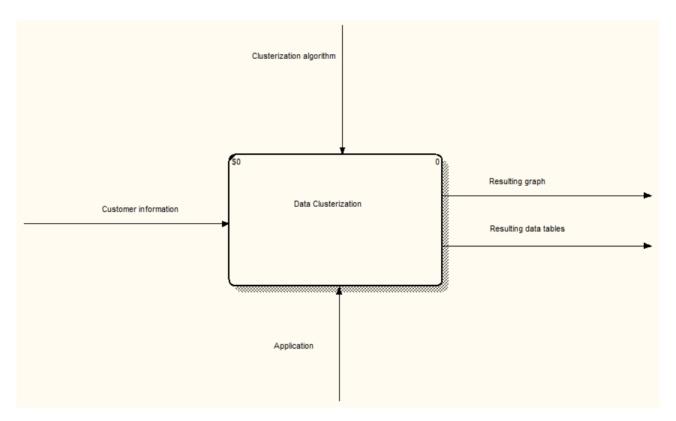


Рисунок 1 — Контекстная SADT-диаграмма системы

На рисунке 2 приведено описание бизнес-процесса в BPMN. На выходе действия: «Загрузить данные покупателей», «Провести анализ данных», «Выполнить кластеризацию», «вывести результаты».

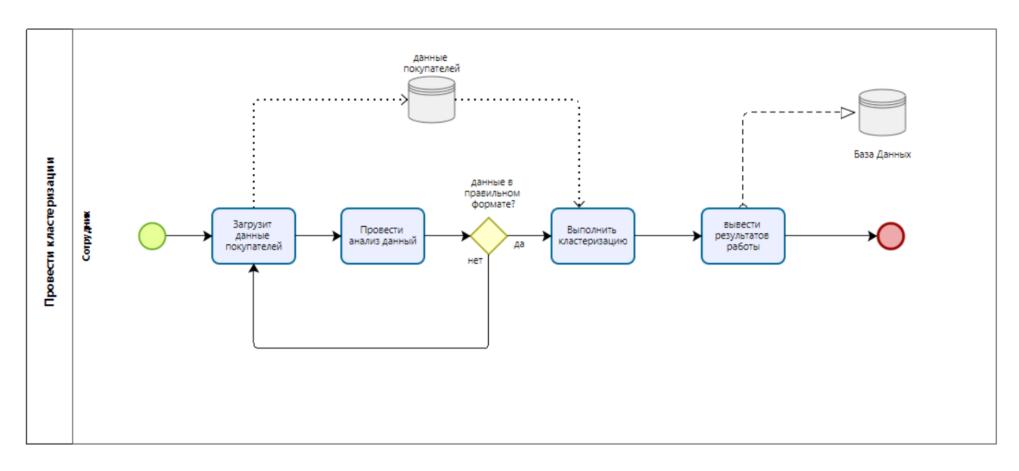


Рисунок 2 – Описание бизнес-процесса «Заключение договора» в BPMN

1.1.1 Алгоритма K-means кластеризации

Создаваемая программа будет использовать метод кластеризации K-means.

Алгоритм K-means - это итеративный алгоритм, который пытается разделить набор данных на заранее определенные K отдельных неперекрывающихся подгрупп (кластеров), где каждая точка данных принадлежит только одной группе. Он пытается сделать точки данных внутри кластера как можно более похожими, но при этом сохраняя кластеры как можно более разными. Он назначает точки данных кластеру таким образом, чтобы сумма квадратов расстояния между точками данных и центроидом кластера (среднее арифметическое всех точек данных, принадлежащих этому кластеру) была минимальной. Чем меньше вариаций внутри кластеров, тем более однородные (похожие) точки данных находятся в одном кластере.

Алгоритм K-means сводится к выполнению следующих шагов:

- 1. Укажите количество кластеров К.
- 2. Инициализируйте центроиды, сначала перетасовав набор данных, а затем случайным образом выбрав К точек данных для центроидов без замены.
- 3. Продолжайте итерацию до тех пор, пока центроиды не изменятся, то есть назначение точек данных кластерам не изменится;
- вычислите сумму квадратов расстояния между точками данных и всеми центроидами,
 - назначьте каждую точку данных ближайшему кластеру (центроиду),
- вычислите центроиды для кластеров, взяв среднее значение всех точек данных, принадлежащих каждому кластеру.

1.1.2 Алгоритм анализа RFM

Алгоритма K-means кластеризации основан на анализ RFM. Суть анализа RFM (Давность, Частота, Денежная стоимость) состоит в том, чтобы разделить клиентов на группы на основе того, как давно они совершили свою последнюю покупку, как часто они покупают товары и какова средняя стоимость их заказов. Для каждой из этих метрик мы назначаем клиентов в одну из трех групп, которым присваивается номер от 1 до 3.

Давность:

- 1 -давние клиенты,
- 2 относительно недавние клиенты,
- 3 последние клиенты.

Частота:

- 1 покупки редко (единичные заказы),
- 2 покупки нечасто,
- 3 покупки часто.

Денежная стоимость:

- 1 низкая стоимость покупок,
- 2 средняя стоимость покупок,
- 3 высокая стоимость покупок.

Анализ RFM-это выгоден для любой компании, в первую очередь потому, что это может помочь в увеличении удержания клиентов, что приведет к увеличению числа откликов -> увеличению коэффициента конверсии -> увеличению дохода для компании, во-вторых, анализ RFM в сочетании с различными другими показателями приоритета может иметь первостепенное значение для поиска моделей поведения клиентов, что также важно для маркетинга, целей продаж и т. д.

Можно выбрать различные способы маркетинга, и затраты могут быть сокращены за счет огромной маржи, поскольку компании не будут тратить

время на дешевых клиентов по сравнению с почти потерянными/потерянными клиентами или начинающими клиентами.

Благодаря анализу RFM денежные лояльные клиенты могут способствовать тому, чтобы компания работала с высококачественным, немного более дорогим продуктом вместо того, чтобы снижать стоимость, приводящую к снижению качества продукции.

Вознаграждение лояльных или потенциально лояльных клиентов может быть осуществлено путем предоставления им бесплатной доставки или предоставления небольших бесплатных услуг или ваучеров, что-то вроде премиальных предложений для крупных платежеспособных клиентов (поскольку не будет беспокойства о больших скидках) и разумной скидки для высокочастотных средних денежных клиентов, следовательно, эффективно сохраняются обе категории, не тратя много усилий и денег.

Могут быть разработаны различные уровни маркетинговых стратегий и может быть осуществлен целевой маркетинг, различные типы стратегий для различных потребностей клиента. Стратегия для покупателей в первый раз может быть настроена на увеличение их частоты, а другая стратегия может быть четко настроена для постоянных клиентов, которые давно не покупали. Подобные действия могут иметь большое значение.

Всегда считается, что один лояльный клиент лучше, чем 100 иррациональных клиентов. Приведенный выше анализ явно помогает сделать более лояльных клиентов более эффективными. Усилия, которые были потрачены впустую раньше на привлечение 10 000 потенциальных клиентов, теперь используются для того, чтобы сосредоточиться и сконцентрироваться на 500 клиентах с высокими шансами, что является большим стимулом для доходов компании.

Анализ RFM может быть использован для улучшения маркетинга по электронной почте, запуска новых продуктов, настройки маркетинговых затрат, повышения вовлеченности пользователей и понимания клиентской базы компании и эффективного ее увеличения.

Почти все компании, занимающиеся электронной коммерцией, продуктами питания и блогами, используют этот тип анализа для увеличения доходов. Например, Flipkart или Amazon делают интенсивный маркетинг, основанный на стратегии, и предоставляют скидки/предложения, основанные на вышеизложенном. Zomato делает то же самое с самого начала, чтобы сохранить своего клиента, несмотря на растущую конкуренцию.

Несколько недостатков: многие клиенты покупают только один раз, усилия и признание их тратятся впустую, из-за интенсивного целевого маркетинга, другие потенциальные крупные клиенты намеренно игнорируются, и не всегда статистика приводит к успеху.

Однако положительные стороны явно перевешивают отрицательные, и, следовательно, анализ RFM является лучшим способом по сравнению с другими примитивными методами.

1.2 Обзор и анализ возможных альтернатив

Интеллектуальная система кластеризации для продуктового магазина очень распространена в таких торговых структурах, как:

- интернет-магазины, предлагающие товары, такие как ebay, amazon, avito,
 - музыкальные приложения, предлагающие музыку как spotify,
- приложения для просмотра фильмов, такие как netflix, для составления предложений для фильмов, которые могут понравиться пользователю.

1.3 Анализ функциональных и эксплуатационных требований

1.3.1 Стандарты

Программный продукт разрабатывается на основании следующих государственных стандартов:

- 1. Межгосударственный стандарт ГОСТ 2018 «Система стандартов по информации, библиотечному и издательскому делу. Отчет о научно исследовательской работе. Структура и правила оформления».
- 2. Международный стандарт ISO/IEC 12207. Информационные технологии. Процессы жизненного цикла программного обеспечения.
- 3. ГОСТ 34.601-90. Автоматизированные системы. Стадии создания.
- 4. ГОСТ 34.602-89. Информационная технология. Комплекс стандартов на автоматизированные системы. Техническое задание на создание автоматизированной системы.
- 5. ГОСТ 34.603-92. Информационная технология. Виды испытаний автоматизированных систем.

1.3.2 Функциональные требования пользователя

Программный продукт, разрабатываемый в рамках курсового проекта, должен удовлетворять следующему перечню функциональных требований:

- формирование групп на основе кластеризации,
- обеспечение доступа к истории покупок клиентов,
- обеспечение просмотра различных кластеризованных групп с целью формирования предложений для рекламы.

1.3.3 Входные данные

Входными данными при работе с программным продуктом должны быть данные клиентской базы данных: имена, купленные продукты, даты по-купок. В формате xls. Входной язык приложения – английский.

1.3.4 Выходные данные

Выходные данные во время работы программы являются группы кластеризованных данных, отображаемые в формате xls.

1.3.5 Требования к интерфейсу

Главное меню программного продукта должно позволять пользователю выбрать данные о покупателе и выполнить кластеризацию этих данных.

Остальные окна программного продукта должны быть оснащены подсказками, а их функции быть интуитивно понятны пользователю.

Сообщения, выдаваемые программой при прохождении каких-либо действий, должны содержать краткое описание произведенных действий и содержать комментарии для облегчения дальнейшей работы пользователя.

1.3.6 Требования к надежности

При работе с программным продуктом необходимо предусмотреть:

- контроль вводимой информации, т.е. возможность отслеживания ошибок, допускаемых пользователем, и последующей реакции программы на них;
- блокировку некорректных действий пользователя при работе с системой.

1.3.7 Требования к программной документации

В состав сопровождающей документации программного продукта должны входить следующие компоненты:

1. Пояснительная записка на 40-60 листах, содержащая описание разработки.

- 2. В приложении к пояснительной записке исходные тексты основных модулей на языке Python.
 - 3. Пояснительная записка, исходные тексты модулей

1.3.8 Требования к составу и параметрам технических средств

Система должна работать на IBM совместимых персональных компьютерах. Минимальные требования:

- тип процессора –Intel®core™ i5-8300H;
- объем оперативного запоминающего устройства 16 Мб;
- тип система 64-bit Operating System
- − тип монитора − HD (15′).

1.3.9 Модель вариантов использования

1.3.9.1 Диаграмма вариантов использования

Действующие лица для диаграммы вариантов использования приведены в таблице 1.

Таблица 1 – Действующие лица

Термин	Значение
Сотрудник	Лицо, использующее программного продукта

Таблица 2 – Таблица вариантов использования

Термин	Значение
Сотрудник	Сотрудник продуктового магазина с необходимыми
	административными привилегиями, пользующийся
	услугами системы кластеризации
Ввод данных о поку-	Ввод данных о покупатели в формате xls для кла-
патели	стеризации
Вход в систему	Ввод пользователем логина и пароля для доступа к
	системе (для Сотрудник)
Вывод результатов	Вывода результатов в формате граф и таблицы
Выполнить класте-	Выполняет кластеризацию и составляет результаты
ризацию	выполнение
Проверка корректно-	Проверка корректности данных для того чтобы не
сти данных	произошли ошибки при кластеризации

На основании всех выше рассмотренных вариантов использования была составлена диаграмма вариантов использования, представленная на рисунке 3 и рисунке Б.2.

1.3.9.2 Описание варианта использования «Выполнить кластеризацию»

Действующие лица: сотрудник.

Заинтересованные лица и их требования:

сотрудник хочет выполнить кластеризации над данными о покупателях;

Предусловия: клиент должен войти в систему.

Постусловия: если вариант использования выполнен успешно, пользователь выполняет кластеризации, сохраняет результаты. В противном случае состояние системы не изменяется.

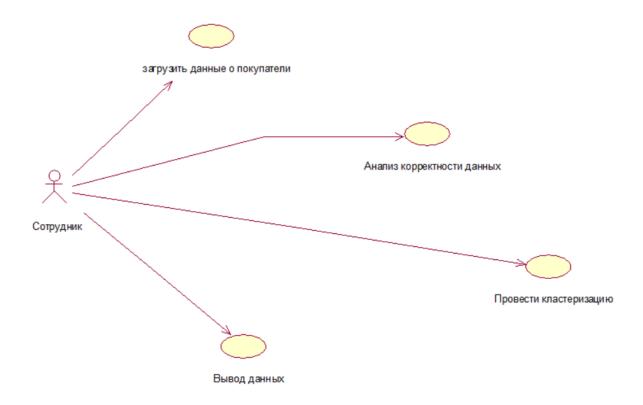


Рисунок 3 – Диаграмма вариантов использования «Выполнить кластеризации»

Основной сценарий.

- 1. Сотрудник выбирает «Clusterize».
- 2. Система выполняет кластеризацию над данными.
- 3. Система отображает отчеты в виде графов и таблиц.
- 4. Система предлагает сохранить результаты.
- 5. Сотрудник выбирает сохранение результатов.
- 5а. Если сотрудник выбирает не сохранять результаты, то вариант использования завершается.

2 Проектирование информационной системы

2.1 Разработка архитектуры системы

Разрабатываемое приложение представляет собой локальное приложение.

Персональные компьютеры должны быть расположены, чтобы сотрудник мог работать с приложением и принтером.

На рисунке 4 представлена предварительная схема развертывания разработанного приложения - архитектура аппаратного обеспечения системы.

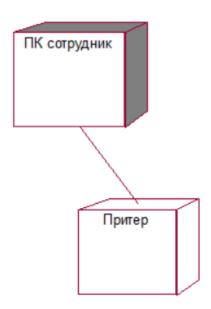


Рисунок 4 – Архитектура технических средств системы

2.2 Разработка модели предметной области

Пользуясь списком категорий и методом анализа словесного описания вариантов использования, составлен список на роль концептуальных классов

для предметной области. Он соответствует требованиям и принятым упрощенным системам для всей предметной области.

Список концептуальных классов:

- Xls документ;
- Анализ;
- Результат работы;
- Результирующий документ;
- Результирующий граф;
- Кластер;
- Сотрудник;
- Покупка.

На основании анализа словесного описания варианта использования, составлен список ассоциаций для предметной области, представленный в таблице 3.

Таблица 3 – Ассоциации для модели предметной области

Ассоциация	Описание ассоциации		
Проводится по	Анализ проводится по покупкам		
Вычисляется	По результирующему xls доку-		
	мент вычисляются кластеры		
Выполняет	Сотрудник выполняет анализ		
Является результатом	Результирующий xls документ		
	является результатом анализа		
включает	Кластеры включает результиру-		
	ющий график		
включает	Кластеры включает результиру-		
	ющий таблицу		
включает	результирующий таблицу вклю-		
	чает результаты работы		
включает	результирующий график включа-		

ет результаты работы	
r y r	

На основании анализа технического задания и описания вариантов использования выделены атрибуты классов для модели предметной области, представленные в таблице 4.

Таблица 4 – Атрибуты классов для модели предметной области

Название класса	Атрибуты класса
Анализ	Столбец даты покупки
	Столбец с именами клиентов
	Столбец выручки клиента
Покупка	Название компания
	Количество покупок
	Дата покупки
	Тип покупки
Сотрудник	ФИО
	Дата рождение
	Название компания
	Позиция в компании
Кластер	координаты точек
Результирующий таблицы	столбцы таблицы
Результирующий график	График (Graph.png)
Результирующий xls документ	xls документ после Анализа
Результаты работы	3D рисунки в формате png, данные
	сотрудник, выполняющий класте-
	ризации и название магазина, дата.

В результате объединения концептуальных классов, ассоциаций и атрибутов классов концептуальная модель предметной области имеет вид, показанный на рисунке 5 и рисунок Б.4.

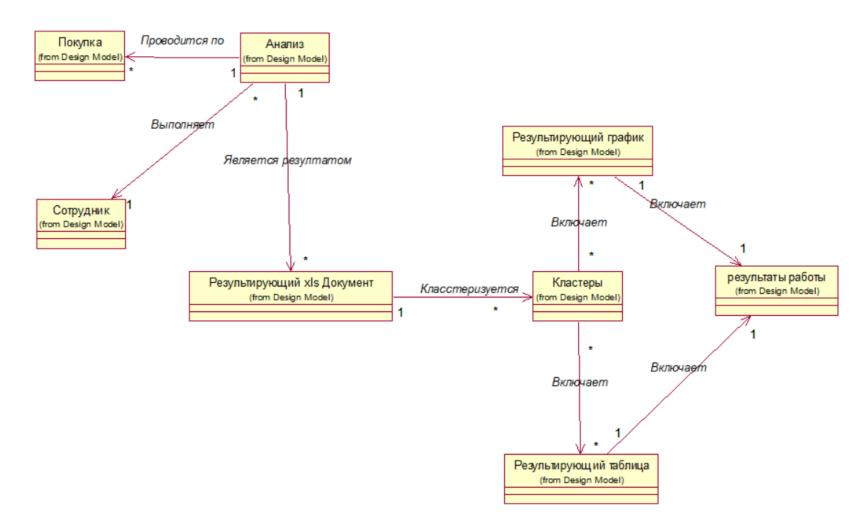


Рисунок 5 — Концептуальная модель предметной области

2.3 Разработка алгоритма функционирования системы

Вход в систему осуществляется сотрудником без проверки имени и пароля.

Алгоритм работы системы в виде диаграммы деятельности приведен на рисунке 6.

В главном меню пользователю дается на выбор несколько действий: «Загрузить», «Анализировать», «Кластеризовать данные», «Сохранить» и «Выход».

Диаграмма деятельностей «Деятельность кластеризация» приведен на рисунке 7 и рисунке Б.3.

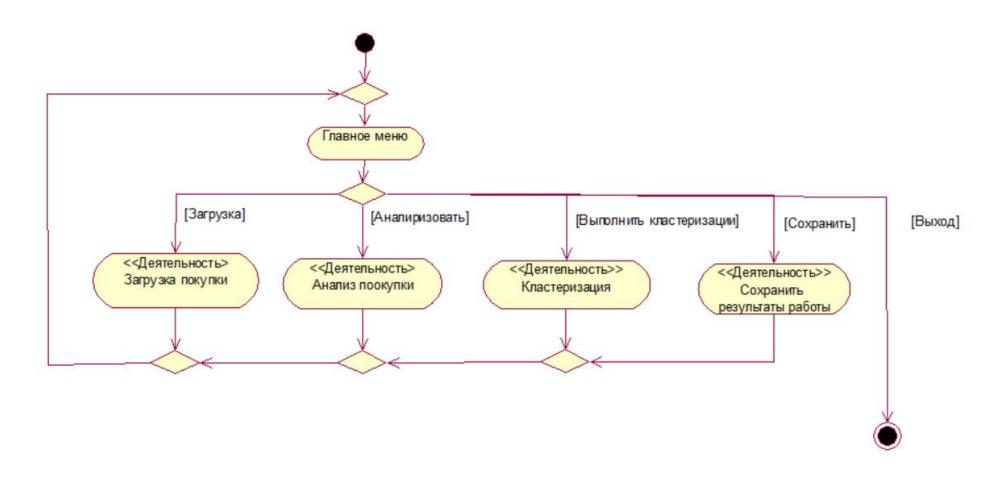


Рисунок 6 – Диаграмма деятельностей «Деятельность алгоритм работы системы»



Рисунок 7 – Диаграмма деятельностей «Деятельность кластеризация»

2.4 Проектирование интерфейса пользователя

На основании алгоритма функционирования и требований к интерфейсу (см. раздел 1) разработана диаграмма состояний представлен на рисунке 8 и рисунке Б.8.

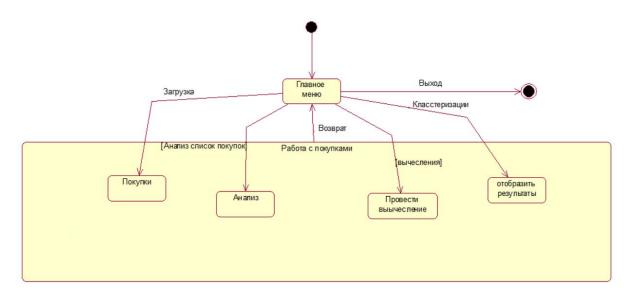


Рисунок 8 – Диаграмма состояний интерфейса

2.5 Реляционная модель данных

На рисунке 9 и рисунке Б.9 изображена реляционная модель данных.

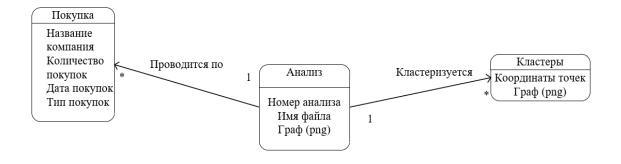


Рисунок 9 – Реляционная модель данных

Реляционная модель данных разработана на основе концептуальной модели предметной области. Реляционная модель данных в дальнейшем служит для разработки БД.

2.6. Проектирование классов предметной области

2.6.1. Построение диаграмм последовательностей для варианта использования «Выполнить кластеризацию»

Диаграмма последовательности, описывающая основной поток событий изображена на рисунке 10 и рисунок Б.7.

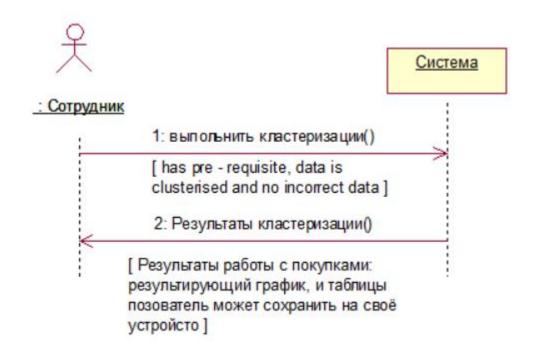


Рисунок 10 — Диаграмма последовательности системных операций варианта использования «выполнить кластеризации»

2.6.2 Построение диаграммы кооперации

Структурные особенности передачи и приема сообщений между объектами представлены на диаграмме кооперации на рисунке 11 и рисунке Б.б.

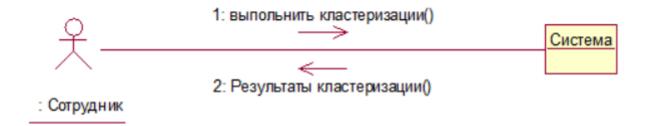


Рисунок 11 – Диаграмма кооперации

3 Реализация системы

3.1 Реализация программного обеспечения системы

3.1.1 Разработка диаграммы компонентов

Реализация программного обеспечения системы представлена на рисунке 12 и рисунке Б.5 в виде Главная форма. Она определяет архитектуру разрабатываемой системы на физическом уровне и представляет зависимости между программными компонентами.

3.1.2 Объекты интерфейса пользователя

Программный продукт состоит из одной формы. Внешний вид формы программы (Main) представлен на рисунке 13.

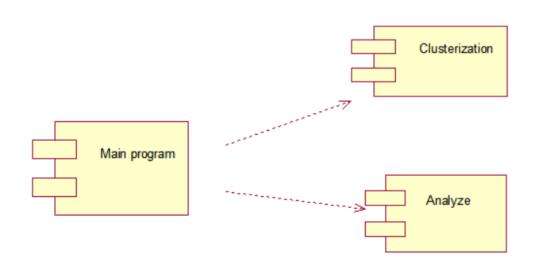


Рисунок 12 – Диаграмма компонентов приложения



Рисунок 13 – Главная форма

В таблице 5 представлены расположенные на форме MAIN компоненты.

Таблица 5 – Компоненты формы MAIN

	Наименование	Тип компонен-	Назначение
No	компонента	та	
	menuStrip1	MenuStrip	Панель инструментов
0			
	Tab1	TableWidget1	Логин и регистрация
1		_	
	Tab2	TableWidget1	Главная страница
2		_	-
	Tab3	TableWidget1	Для отображение загруженных
3		_	ых
	Tlabel1	Tlabel	Текущий открытый файл
4			
	Tlabel2	Tlabel	Недавно открытые файлы
5	Tlabel3		
	Tlabel4		
	TButton1	TButton	Загрузить файл
6			
	TButton2	TButton	Сохранить файл
7			

Продолжение таблицы 5

	Наименование	Тип компонен-	Назначение
No	компонента	та	
	Combobox1	TCombobox	Выбрать столбец id покупателей
8			
	Combobox2	TCombobox	Выбрать столбец дата покупок
9			
	Combobox3	TCombobox	Выбрать столбец доходов
10			
	TButton3	TButton	Выполнить анализ
11			
	Combobox4	TCombobox	Выбрать число recency
12			
	Combobox5	TCombobox	Выбрать число frequency
13			
	Combobox6	TCombobox	Выбрать число Monetary
14			
	TButton4	TButton	Выполнить кластеризации
15			

4 Тестирование и оценка трудоемкости разработки программного продукта

4.1 Тестирование программного продукта

4.1.1 Функциональное тестирование

На основе функциональных требований (1.3.2) могут быть сформулированы следующие тест-требования.

Тест-требования

- 1. Проверить, что разработанный программный продукт обеспечивает формирование групп на основе кластеризации.
- 2. Проверить, что разработанный программный продукт обеспечивает доступа к истории покупок клиентов.
- 3. Проверить, что разработанный программный продукт обеспечивает просмотра различных кластеризованных групп с целью формирования предложений для рекламы.

Результаты функционального тестирования представлены в таблице 6. Таблица 6 – Результаты тестирования пользовательского интерфейса

Номер	Номер соответ-	Сценарий вы-	Реакция си-	Результат
тестового	ствующего тесто-	полнения те-	стемы	(пройден /
примера	вого требования	стового при-		не прой-
		мера (дей-		ден)
		ствие опера-		
		тора)		
1	1	Откройте	Появляется	Пройден
		файл покупки	граф гриппов	
		и выполняете		
		кластеризации		
2	2	Нажмите на	Откроется	Пройден
		кнопку (Ореп	окно сохра-	
		Project)	нённых фай-	
			лов	

Продолжение таблицы 6

Номер	Номер соответ-	Сценарий вы-	Реакция си-	Результат
тестового	ствующего тесто-	полнения те-	стемы	(пройден /
примера	вого требования	стового при-		не прой-
		мера (дей-		ден)
		ствие опера-		
		тора)		
3	3	Выполняете	Появляется 4	Пройден
		кластеризации	графы с кото-	
			рыми можно	
			создавать	
			предложения	
			покупателей	

4.1.2 Тестирование пользовательского интерфейса

На основе требований к интерфейсу (1.3.5) могут быть сформулированы следующие тест-требования.

Тест-требования

- 1. Проверить, что главное меню программного продукта позволяет пользователю выбрать данные о покупателе.
- 2. Проверить, что главное меню программного продукта позволяет пользователю выполнить кластеризацию данных покупателей.

Результаты тестирования пользовательского интерфейса представлены в таблице 7.

Таблица 7 – Результаты тестирования пользовательского интерфейса

Номер	Номер соответ-	Сценарий вы-	Реакция си-	Результат
тестового	ствующего тесто-	полнения те-	стемы	(пройден /
примера	вого требования	стового при-		не пройден)
		мера (дей-		
		ствие опера-		
		тора)		
1	1	Откройте	Появляется	пройден
		файл покупки	таблица с	
			данными по-	
			купателей	

Продолжение таблицы 7

Номер	Номер соответ-	Сценарий вы-	Реакция си-	Результат
тестового	ствующего тесто-	полнения те-	стемы	(пройден /
примера	вого требования	стового при-		не пройден)
		мера (дей-		
		ствие опера-		
		тора)		
2	2	Нажмите на	Появляется	пройден
		кнопку (Апа-	несколько	
		lyze) и (Clus-	графов	
		terize)		

4.1.3 Модульное тестирование

Создание теста для метода RFM_dataframe класса Analyze() модули Analysis используя библиотеки unitest и pandas.testing в питоне.

Чтобы использовать unittest в тестовом классе, он должен быть унаследован от того класса, в котором мы собираемся его использовать, например:

class TestApp(unittest.TestCase):

Имена методов в тестовом классе должны предшествовать слова Test_, чтобы класс распознал, что метод является тестовой функцией.

В первом тестовом примере функция Analyze возвращает фрейм данных RFM - Recency, Frequency и Monetary dataframe. Было бы обременительно тестировать фрейм данных с помощью unitest, поэтому используется pandas.testing. Pandas.testing имеет специальные функции, которые позволяют сравнивать свойства двух фреймов данных, просто изменяя параметры функций.

Входной данных:

Состоит из столбцов идентификации; данные о покупателях, даты покупки, сумма, потраченная конкретным покупателем на конкретную дату.

data =

{'Order ID': ['CA-2016-152156', 'CA-2016-152156', 'CA-2016-138688', 'US-2015-108966', 'US-2015-108966', 'CA-2014-115812', 'CA-2014-115812'],

```
'Order Date': ['11/8/2016', '11/8/2016',
'11/8/2016','10/11/2015','10/11/2015','6/9/2014','6/9/2014'],
'Profit': ['261.96', '731.94','14.62','957.5775','22.368','48.86','7.28']
}
```

Ожидаемые выходные данные:

Состоит из; строка идентификации клиента, частота посещений клиентов, время последнего посещения клиента и доход, который принес клиент.

Класс Analyze имеет один основной метод, который возвращает фрейм данных, 4 теста выполняются на результирующем фрейме данных. Для тестирования результирующего фрейма данных используется метод assert_dataframe_equal из panadas.testing, этот метод имеет много параметров, но из них только четыре являются полезными в данном случае.

Тест 1

Эта функция предназначена для сравнения двух DataFrames и вывода любых различий.

```
\label{lem:def-test-Analyze-I} def\ test\_Analyze\_I(self): \\ pd\_testing.assert\_frame\_equal(Analyze(data\_df,1,2,3).RFM\_dataframe(),result\_df,False,False,False,False)
```

Тест 2

Проверять, идентичен ли dtype DataFrame. *def test_Analyze_2(self):*

 $pd_testing.assert_frame_equal(Analyze(data_df,1,2,3).RFM_dataframe($ $), result_df, True, False, False, False)$

Тест 3

Следует ли проверять класс столбцов, dtype и inferred_type идентичны. def test_Analyze_3(self):

 $pd_testing.assert_frame_equal(Analyze(data_df,1,2,3).RFM_dataframe($ $), result_df, False, False, True, False)$

Тест 4

Проверять, идентичен ли класс DataFrame.

def test_Analyze_4(self):

 $pd_testing.assert_frame_equal(Analyze(data_df,1,2,3).RFM_dataframe(),result_df,False,False,False,True)$

После завершения тестирования открывается окно обозревателя тестов, в котором отображаются результаты (рисунок 13).

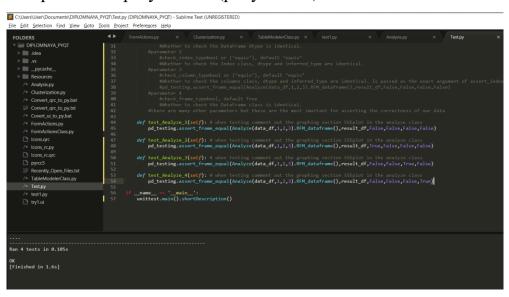


Рисунок 13 – Вывод успешно выполненного теста

4.2 Оценка трудоемкости создания программного продукта

Для разработанного программного продукта был выбран метод оценки трудоемкости разработки программных продуктов на основе функциональных

указателей. Данный метод позволяет наиболее точно оценивать т. к. полученные результаты основаны на информационные характеристики компоненты.

Исходные данные.

Функции разрабатываемой системы:

- формирование групп на основе кластеризации,
- обеспечение доступа к истории покупок клиентов,
- обеспечение просмотра различных кластеризованных групп с целью.

Ввод и накопление информации: данные в виде текста программы вводятся с клавиатуры, настройки системы производятся пользователем с помощью форм программы. Информация, относящаяся к системе, хранится в базе данных.

Состав входной информации:

Входными данными при работе с программным продуктом должны быть данные клиентской базы данных: имена, купленные продукты, даты покупкой. В формате xls. Входной язык приложения – английский.

Выделенные согласно методике информационные характеристики показаны в таблице 8.

Таблица 8 – Информационные характеристики

Наименование	Число элементов данных	Число ссылок на файлы / Типы эле- ментов записей	Ранг
Внешние вводы:			
1. Форма главная	13	1	3
2. Форма управления	4	0	3
Внешние выводы:			
1. Форма результатов анализа	10	0	4
Внутренние логические файлы:			
1. Форма таблиц	1	1	7
Общее количество рангов			17

таблице 9.

Таблица 9 – Значения системных параметров приложения

№	Системный параметр	Значение (Fi)
1	Передача данных	0
2	Распределенная обработка данных	0
3	Производительность обработки	4
4	Эксплуатационные ограничения	0
5	Частота транзакций	0
6	Ввод данных в режиме «онлайн»	0
7	Эффективность работы	1
8	Онлайновое обновление	0
9	Сложная обработка	1
10	Повторное использование	1
11	Простота установки	0
12	Простота эксплуатации	0
13	Количество возможных установок на различных	1
	платформах	
14	Простота изменений (гибкость)	1
Ито	το (Σ Fi)	9

Количество функциональных указателей вычисляется по формуле FP = Общее количество рангов \times (0,65 + 0,01 \times Σ Fi) с учетом данных таблиц1 и 2.

$$FP = 17 \times (0.65 + 0.01 \times 9) = 12.58.$$
 [1]

Полученная FP-оценка пересчитывается в LOC-оценку V, учитывая, что ПП создается с использованием среды питон.

$$V = K_{93} \times FP = 12,58. \times 55 = 0,692 \text{ KSLOC}.$$
 [2]

Разрабатываемое ПО относится в полунезависимому, поэтому берёмсоответствующие коэффициенты N1, N2, N3.

Согласно формуле $T=N1 \times KSLOC^{N2}$ трудоемкость создания ППсоставляет

$$T = 3.0 \times 0,692$$
 ^{1,12} = 1,99 чел. мес. [3]

Время разработки ПП составляет согласно формуле tразр = $2.5 \times T^{N3}$ составляет

tpa3p =
$$2.5 \times 1.99^{0.35} = 3.2$$
 Mec. [4]

Результаты расчета:

- 1) трудозатраты на разработку проекта составят: 1,99 чел. мес,
- 2) время разработки составит: 3,2 мес.

Согласно полученным результатам вычислений трудоёмкости, данный проект может быть реализован командой разработчиков за срок 3,2 месяца в то же время реальное время разработки не может превышать (или составило) 9 месяцев, что позволяет сделать вывод о ... (качестве проведения оценки трудоемкости, о возможности реализации проекта в рамках выпускной квалификационной работы).

Заключение

Разработанный программный продукт позволяет автоматизировать процесс кластеризации пользователей продуктового магазина. Этот программный продукт упрощает процесс прогнозирования рекламы, программный продукт может использоваться в качестве подсистемы в приложении для сокращения количества приложений.

В процессе создания системы в соответствии с заданием были разработаны: модель вариантов использования, концептуальная модель предметной области, диаграммы деятельности, реляционная модель данных, диаграмма состояний интерфейса, формы интерфейса и диаграмма компонентов. Была выполнена частично проверка и отладка системы.

Система позволяет осуществить:

- формирование групп на основе кластеризации,
- доступ к истории покупок клиентов,
- просмотр различных кластеризованных групп с целью формирования предложений для рекламы.

В данной выпускной квалификационной работе было проведено программирование на языке Python. Главное меню, события кнопок, визуальная составляющая проекта прописаны в приложения qt Designer, функции выполняющий кластеризации были прописаны на языке Python 3.9. Главное меню программного продукта позволяет выбрать файл, содержащий данных покупателей, выполнит анализ и выбрать значение на кластеризации и выполнит кластеризации над данными.

Таким образом, в бакалаврской работе удалось реализовать интеллектуальную систему кластеризации для продуктового магазина, которая удовлетворяет заданным требованиям.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1. Обзор алгоритмов кластеризации [Сайт]. URL: https://scikit-learn.org/stable/modules/clustering.html с/ (дата обращения: 01.10.2020).
- 2. Интерфейс на питон [Сайт]. URL: / Обзор алгоритмов кластеризации [Сайт]. URL: https://www.riverbankcomputing.com/static/Docs/PyQt5/ (дата обращения: 01.10.2020).
- 3. Обзор алгоритмов кластеризации [Сайт]. URL: https://scikit-learn.org/stable/modules/clustering.html/ (дата обращения: 01.03.2021).
- 4. RFM алгоритмов [Сайт]. URL: https://www.ibm.com/docs/en/spss-statistics/27.0.0?topic=analysis-rfm-scores-from-customer-data (дата обращения: 01.01.2021).
- 5. PyQt табличный структуры [Сайт]. URL: https://www.mfitzp.com/tutorials/qtableview-modelviews-numpy-pandas/ (дата обращения: 16.05.2021).
- 6. Использование метода локтя для определения оптимального количества кластеров для кластеризации k-средних [Сайт]. URL: https://bl.ocks.org/rpgove/0060ff3b656618e9136b/ (дата обращения: 01.11.2020).
- 7. Наборы данных [Сайт]. URL: https://www.kaggle.com/vijayuv/onlineretail/ (дата обращения: 01.02.2021).
- 8. RFM-анализ для сегментации клиентов и маркетинга лояльности [Сайт]. URL: https://www.youtube.com/watch?v=OYohJxp219k/ (дата обращения: 25.01.2021).
- 9. RFM-анализ для сегментации клиентов и маркетинга лояльности [Сайт]. URL: https://www.ibm.com/docs/en/spss-statistics/27.0.0?topic=marketing-direct/ (дата обращения: 25.01.2021).

Приложение А Текст программы

import required libraries for dataframe and visualization

import numpy as np
import pandas as pd

from mpl_toolkits.mplot3d import Axes3D
import matplotlib.pyplot as plt

import datetime as dt

import required libraries for clustering
import sklearn
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from scipy.cluster.hierarchy import linkage
from scipy.cluster.hierarchy import dendrogram
from scipy.cluster.hierarchy import cut_tree

Recency refers to the interval between the time, that the latest consuming behavior happens,

and present. Many direct marketers believe that most-recent purchasers are more likely to

purchase again than less-recent purchasers. Frequency is the number of transactions that a

customer has made within a certain period. This measure is used based on the assumption

that customers with more purchases are more likely to buy products than customers with

fewer purchases. Monetary refers to the cumulative total of money spent by a particular

```
11 11 11
class Clusterize:
# Reading the data on which analysis needs to be done
                     def init (self, freq k, recen k, rev k,
rfm df ):
                                 self.rfm df = rfm df
                                 self.rfm df
self.frequency cluster(freq k, 'Frequency', self.rfm df)
                     self.rfm df.groupby('FrequencyCluster')['Frequ
ency']
                                 self.rfm df
self.recency_cluster(recen_k, 'Recency', self.rfm_df)
                     self.rfm df.groupby('RecencyCluster')['Recency
' ]
                                 self.rfm df
                                                                  =
self.revenue_cluster(rev_k, 'logRevenue', self.rfm df)
                     self.rfm df.groupby('RevenueCluster')['logReve
nue']
                                 self.rfm df['OverallScore'] =
self.rfm df['RecencyCluster'] + self.rfm df['FrequencyCluster'] +
self.rfm df['RevenueCluster']
                     self.rfm df.groupby('OverallScore')['Recency',
'Frequency','logRevenue'].mean()
```

customer.

```
#self.graphIndividaulMeasures()
                     def
                            order cluster(self, cluster col,
                                                                fea-
ture col, df, ascending):
                                  df new
df.groupby(cluster col)[feature col].mean().reset index()
                                  df new
df new.sort values(by=feature col,ascending=ascending).reset index
(drop=True)
                                  df new['index'] = df new.index
                                  df final
pd.merge(df,df new[[cluster col,'index']], on=cluster col)
                                  df final
df final.drop([cluster col],axis=1)
                                  df final
df final.rename(columns={"index":cluster col})
                                  return df final
                          frequency cluster(self, cluster number,
frequency col, dataframe):
                                  frequency kmeans
KMeans(n clusters=cluster number)
                                  frequen-
cy kmeans.fit(dataframe[[frequency col]])
                     # Assigning cluster prediction to customers
                                  dataframe['FrequencyCluster']
frequency kmeans.predict(dataframe[[frequency col]])
                     # Ordering clusters from low to high and iden-
tifying statistics
                                  dataframe
self.order cluster('FrequencyCluster', frequency col, dataframe,
True)
```

self.graphClusters()

return dataframe

```
def recency_cluster(self, cluster_number, re-
cency col, dataframe):
                                 recency kmeans
                                                                   =
KMeans(n clusters=cluster number)
                                 recen-
cy kmeans.fit(dataframe[[recency col]])
                     # Assigning cluster prediction to customers
                                 dataframe['RecencyCluster'] = re-
cency kmeans.predict(dataframe[[recency col]])
                     # Ordering clusters from low to high and iden-
tifying statistics
                                 dataframe
self.order cluster('RecencyCluster', recency col, dataframe,
False)
                                 return dataframe
                     def revenue cluster(self, cluster number, rev-
enue col, dataframe):
                                 revenue kmeans
KMeans(n clusters=cluster number)
                                 reve-
nue kmeans.fit(dataframe[[revenue col]])
                     # Assigning cluster prediction to customers
                                 dataframe['RevenueCluster']
revenue kmeans.predict(dataframe[[revenue col]])
                     # Ordering clusters from low to high and iden-
tifying statistics
```

```
dataframe
```

```
self.order_cluster('RevenueCluster', revenue_col,dataframe,True)
```

return dataframe

```
def graphClusters(self):
                                 # Naming and defining segments
                                 self.rfm df['Segment'] = 0
                     self.rfm df.loc[self.rfm_df['OverallScore']>4,
'Segment'] = 1
                     self.rfm df.loc[self.rfm df['OverallScore']>6,
'Segment'] = 2
                                 high = self.rfm df.query('Segment
== 2')
                                 mid = self.rfm df.query('Segment
== 1 ')
                                 low = self.rfm df.query('Segment
== 0'
                                 fig = plt.figure()
                                 ax = fig.add subplot(111, projec-
tion='3d')
                                          (low['Frequency'].values,
                                 g1=
low['Recency'].values, low['logRevenue'].values)
                                          (mid['Frequency'].values,
                                 q2 =
mid['Recency'].values, mid['logRevenue'].values)
                                 q3=
                                         (high['Frequency'].values,
high['Recency'].values, high['logRevenue'].values)
                                 data = [g1, g2, g3]
```

```
['#440154FF',
                                 colors =
'#20A387FF', '#FDE725FF']
                                 groups = ['Low', 'Med', 'High']
                                       data, color, group
                                 for
                                                                in
zip(data, colors, groups):
                                                 x, y, z = data
                                                 ax.scatter(x, y,
z, alpha=0.5, c=color, label=group)
                                 # Make legend
                                 ax.legend()
                                 ax.set xlabel('Frequency')
                                 ax.set ylabel('Recency')
                                 ax.set zlabel('Revenue')
                                 ax.set title('Spatial Representa-
tion of Segments', loc='left')
                                 plt.show();
                    def graphIndividaulMeasures(self):
                                 plt.figure()
                    plt.scatter(list(self.rfm df['RecencyCluster']
) )
                                 plt.show();
```

Приложение Б Программный код модульных тестов

```
import unittest
from Clusterization import Clusterize
from Analysis import Analyze
import pandas as pd
import pandas.testing as pd testing
from matplotlib.testing.decorators import image comparison
data = {'Order ID': ['CA-2016-152156', 'CA-2016-152156', 'CA-2016-
138688','US-2015-108966','US-2015-108966','CA-2014-115812','CA-
2014-115812'],
        'Order Date': ['11/8/2016',
                                                 '11/8/2016',
'11/8/2016','10/11/2015','10/11/2015','6/9/2014','6/9/2014'],
        'Profit':
                                                        ['261.96',
'731.94','14.62','957.5775','22.368','48.86','7.28']
data df = pd.DataFrame (data, columns = ['Order ID','Order
Date','Profit'])
result = {'Order ID':
                                ['CA-2016-152156','CA-2016-
138688','US-2015-108966','CA-2014-115812'],
          'Frequency':
                                [1, 0, 1, 1],
                                [0, 0,394, 883],
          'Recency':
          'logRevenue': [496.95000, 14.62000, 489.97275, 28.07000]
        }
result df = pd.DataFrame (result, columns = ['Order
ID', 'Frequency', 'Recency', 'logRevenue'])
class TestApp(unittest.TestCase):
                    #Analyze(data df,1,2,3).RFM dataframe()
```

" when testing comment out the graphing section SSEplot in the analyze class"

#Analyze assert frame equal parameters:

#parameter 1

#check dtypebool,

default True

#Whether to check

the DataFrame dtype is identical.

#parameter 2

#check_index_typebool or {'equiv'}, default
'equiv'

#Whether to check

the Index class, dtype and inferred type are identical.

#parameter 3

#check_column_typebool or {'equiv'}, default
'equiv'

#Whether to check

the columns class, dtype and inferred_type are identical. Is passed as the exact argument of assert index equal().

#check frame typebool, default True

#Whether to check

the DataFrame class is identical.

#there are many other parameters but these are the most imortant for asserting the correctness of our data

def test_Analyze_1(self): # when testing comment out the graphing section SSEplot in the analyze class

```
1,2,3).RFM dataframe(),result_df,False,False,False)
                     def test Analyze 2(self): # when testing com-
ment out the graphing section SSEplot in the analyze class
                    pd testing.assert frame equal(Analyze(data df,
1,2,3).RFM dataframe(),result df,True,False,False,False)
                     def test Analyze 3(self): # when testing com-
ment out the graphing section SSEplot in the analyze class
                    pd testing.assert frame equal(Analyze(data df,
1,2,3).RFM dataframe(), result df, False, False, True, False)
                     def test Analyze 4(self): # when testing com-
ment out the graphing section SSEplot in the analyze class
                    pd testing.assert frame equal(Analyze(data df,
1,2,3).RFM dataframe(),result df,False,False,False,True)
if __name__ == '__main_ ':
    unittest.main().shortDescription()
```

pd testing.assert frame equal(Analyze(data df,

Приложение В Внешний вид графического материала

Внешний вид графического материала, выполненного на отдельных листах представлен на рисунках 5.1-5.5.

Перечень графического материала:

- лист 1: Постановка задачи (рисунок Б.1),
- лист 2: Диаграмма функциональных требования к системе (рисунок Б.2),
- лист 3: Диаграмма деятельностей «Деятельность алгоритм работы системы» (рисунок Б.3),
- лист 4: Диаграмма концептуальной модели предметной области (рисунок Б.4),
- лист 5: Диаграмма компонентов приложения (рисунок Б.5).
 - лист 6: Диаграмма кооперации (рисунок Б.6).
- лист 7: Диаграмма последовательности системных операций варианта использования «выполнить кластеризации» (рисунок Б.7).
 - лист 8: Диаграмма состояний интерфейса (рисунок Б.8).
 - лист 9: Диаграмма реляционной модели данных (рисунок Б.9).
 - лист 10: Контекстная SADT-диаграмма системы (рисунок Б.10).

KLX:BKP.020303.413.21.11

Постановки задачи

Тема работы: Система сегментации рынка на основе кластеризации

Цель работы: Целью разработки приложений является создание системы кластеризации, которая группирует клиентов определенных интернет-магазинов продуктов в несколько групп и дает предложения о том, какие продукты рекламировать для каждой результирующей группы.

Постановки задачи:

- 1. Формирование групп на основе кластеризации.
- 2. Обеспечение доступа к истории покупок клиентов.
- 3. Обеспечение просмотра различных кластеризованных групп с целью формирования предложений для рекламы.

	H				КП.020303.413.21.15				
Изм Раз Про Т.ко	Лит раб. вер.	№ Докум. Мвеемба Бабюин Бабюин	Подп.	Дата	Подстановка задачи	Литера К Лист	Ma	Лис	тов 1
					Курсовой проект	КГУ МОИАИС			C-413

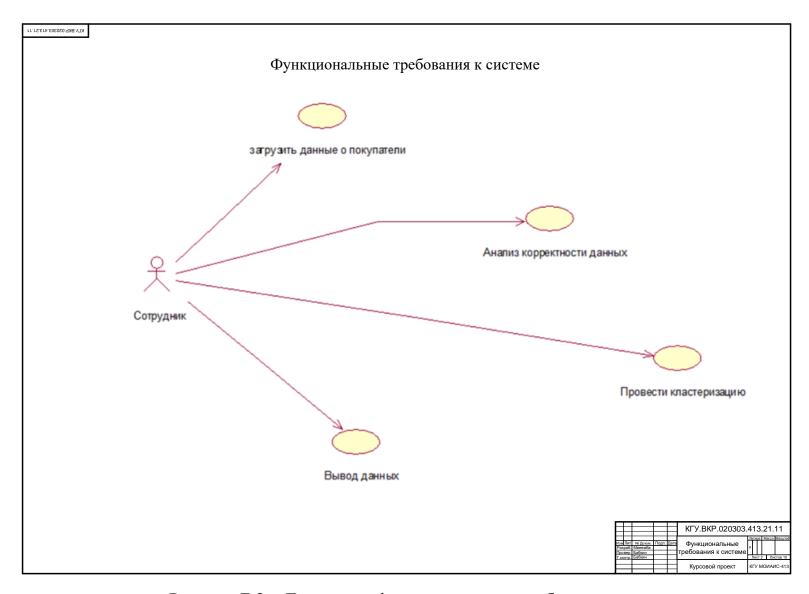


Рисунок Б.2 – Диаграмма функциональных требования к системе

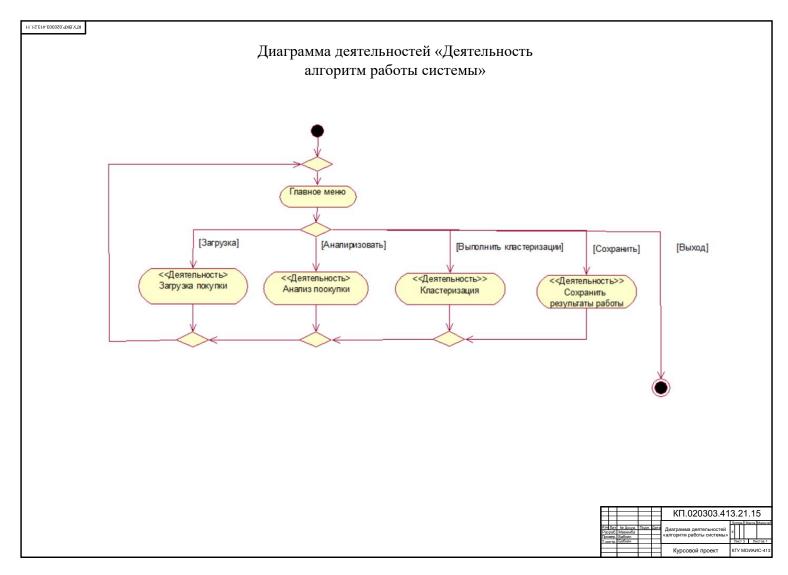


Рисунок Б.3 – Диаграмма деятельностей «Деятельность алгоритм работы системы»

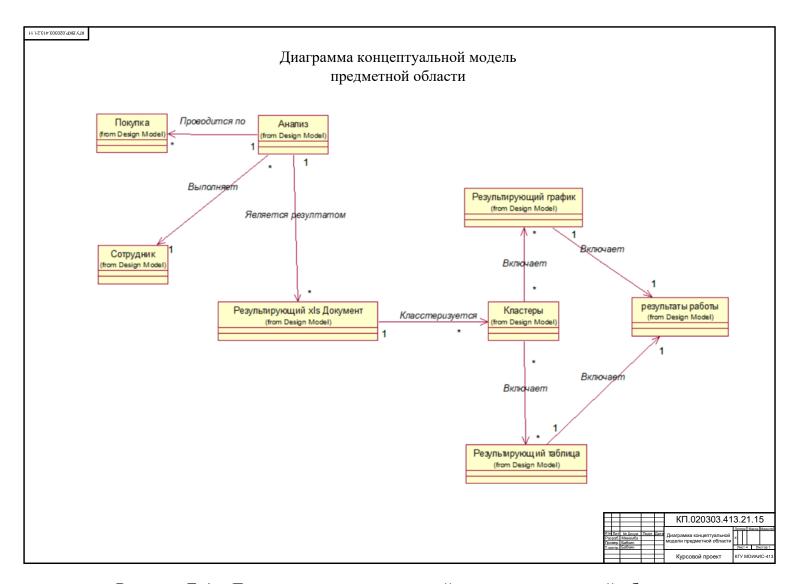


Рисунок Б.4 – Диаграмма концептуальной модели предметной области

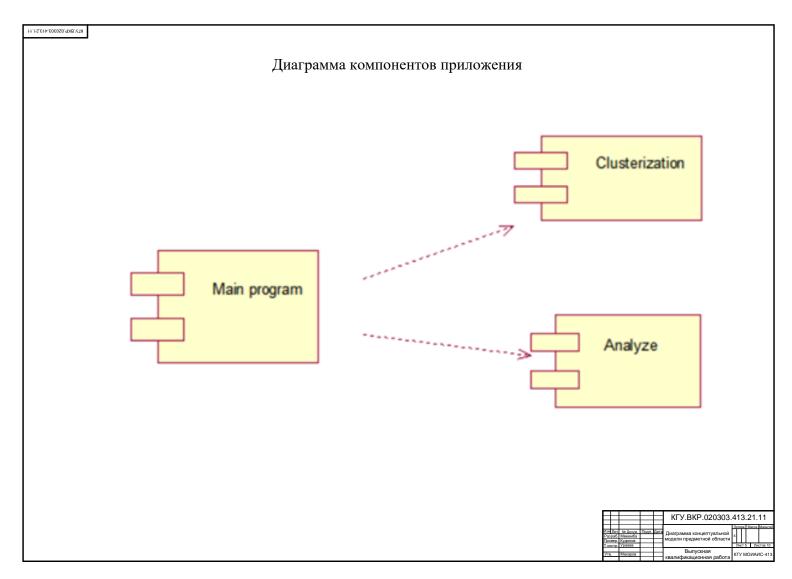


Рисунок Б.5 – Диаграмма компонентов приложения

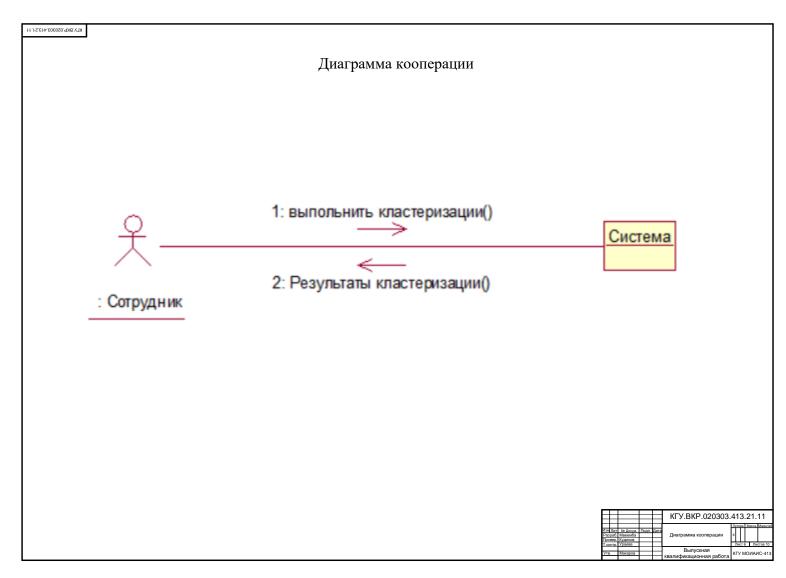


Рисунок Б.6 – Диаграмма кооперации

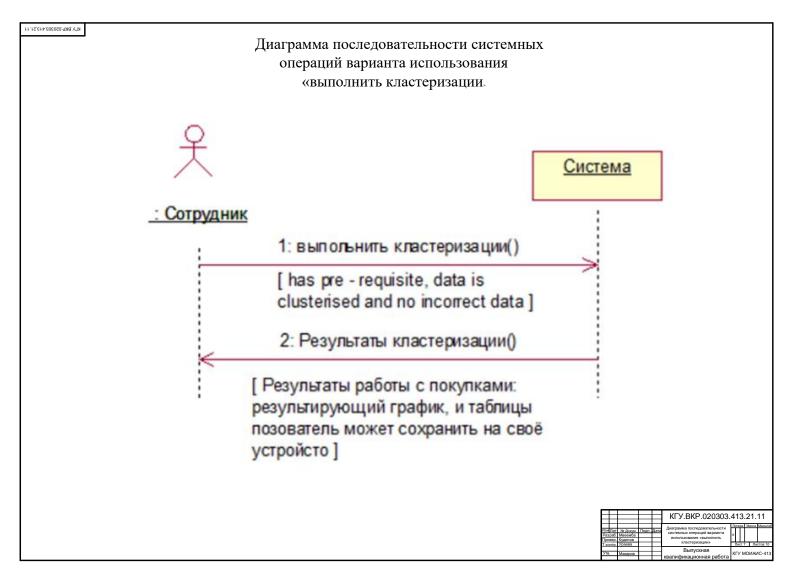


Рисунок Б.7 – Диаграмма последовательности системных операций варианта использования «выполнить кластеризации»

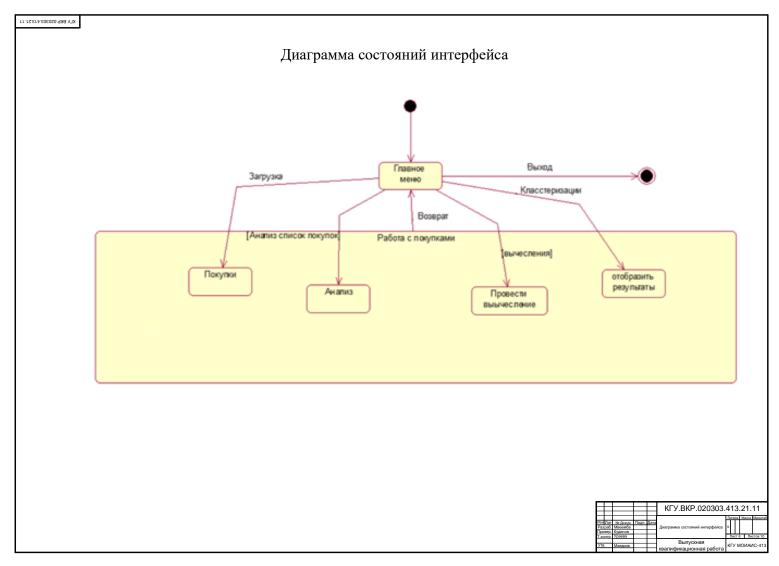


Рисунок Б.8 – Диаграмма состояний интерфейса

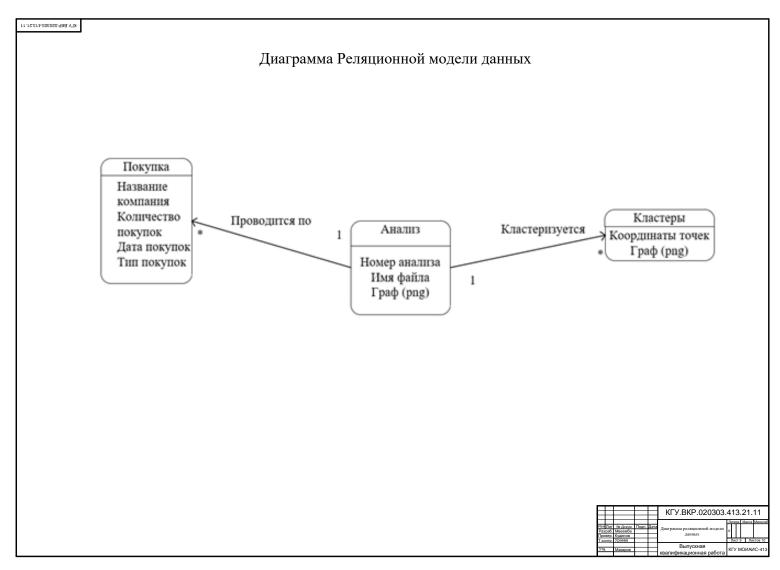


Рисунок Б.9 – Диаграмма реляционной модели данных

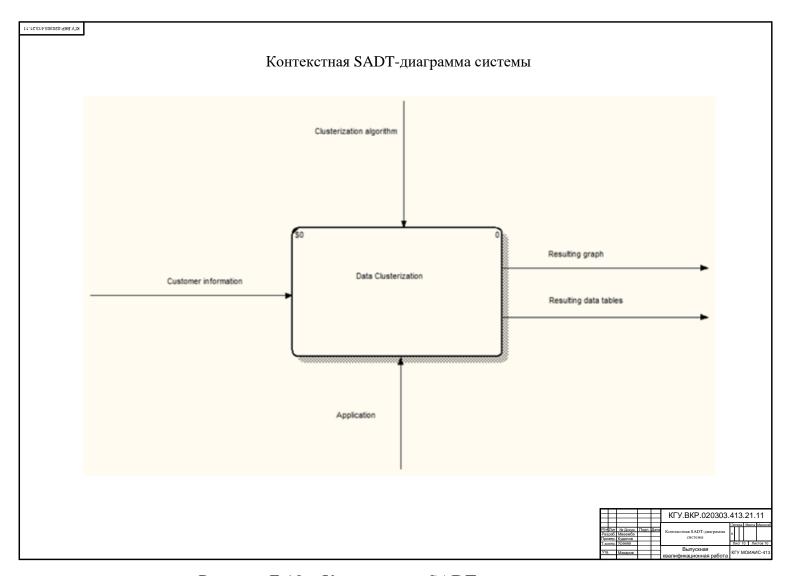


Рисунок Б.10 – Контекстная SADT-диаграмма системы